

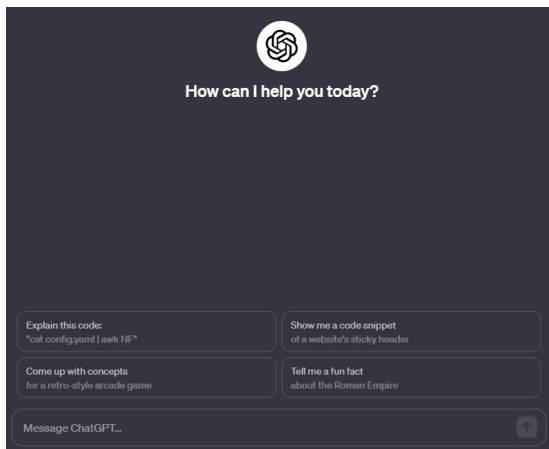
# Deep Learning 101

Capítulo 1: Neurona





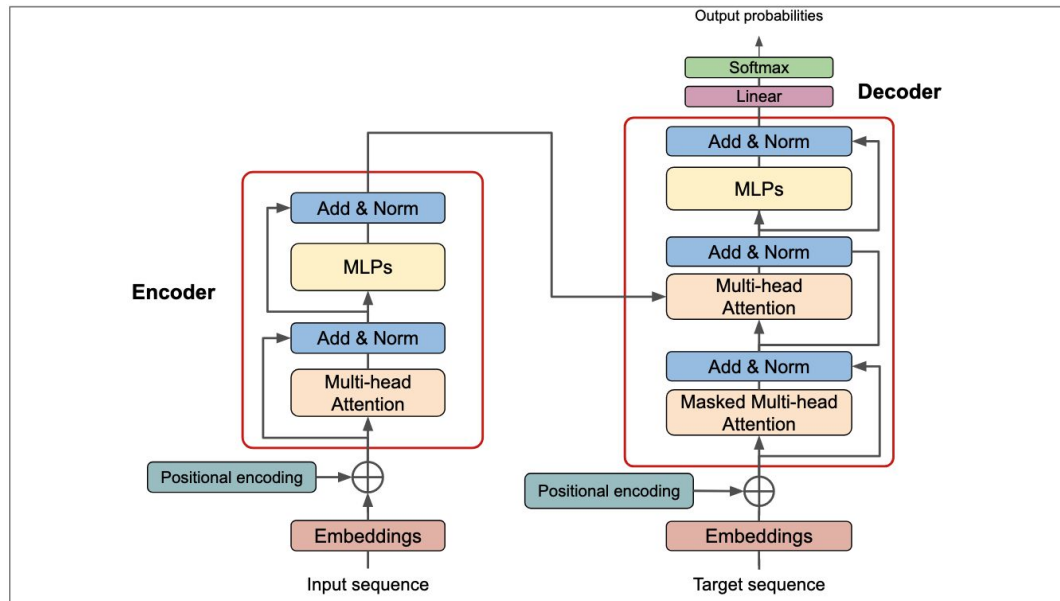
# Overview



ChatGPT




## Modelo “Transformer” (2017)



<https://deepprevious.github.io/posts/001-transformer/>



# Overview



<https://deepreversion.github.io/posts/001-transformer/>



# Agenda

- Problemas que puede resolver una neurona.
- Modelo de neurona: perceptrón.
- Entrenamiento: qué significa que la neurona “aprenda”.
- Implementación desde cero, sin librerías.



# Problema

Clasificación de especies de flores.

Longitud del Sépalo (cm)	Ancho del Sépalo (cm)	Es Iris Setosa
5.1	3.5	1
4.9	3.0	1
6.2	5.4	-1

$x_1$

$x_2$

$y$



# Problema

Estimación del precio de una casa.

Tamaño de la Casa (m <sup>2</sup> )	Precio de la casa (miles de usd)
95	100
134	150
281	375


$x_1$

$y$



# Modelo de neurona: Perceptrón

Su función es hacer predicciones sobre datos de entrada.





# Conjunto de entrenamiento

Se otorgan al perceptrón inputs ( $x_1$ ,  $x_2$ ) con sus respectivos outputs “ $y$ ” esperados.

$x_1$	$x_2$	$y$
1	1	1
2	2	1
1	2	-1





# Predicciones

- El perceptrón calculará una salida (predicción) para cada input.
- Su objetivo será ajustar las predicciones para que coincidan con los datos de entrenamiento.

$x_1$	$x_2$	$y$
1	1	1
2	2	1
1	2	-1

Datos de entrenamiento

$x_1$	$x_2$	$\hat{y}$
1	1	-1
2	2	1
1	2	1


Predicciones




Al inicio, las predicciones  
serán aleatorias.

# Perceptrón


- Datos de entrenamiento:  $x = (x_1, x_2, \dots, x_m)$
- Pesos:  $w = (w_1, w_2, \dots, w_m)$



# Perceptrón: ejemplo



# Perceptrón: bias





$$x = (1, x_1, x_2, \dots, x_m)$$

$$w = (w_0, w_1, w_2, \dots, w_m)$$

# Tipos de perceptrones

Según su función de activación

# Perceptrón escalón





# Perceptrón escalón: usos

- Clasificación binaria.

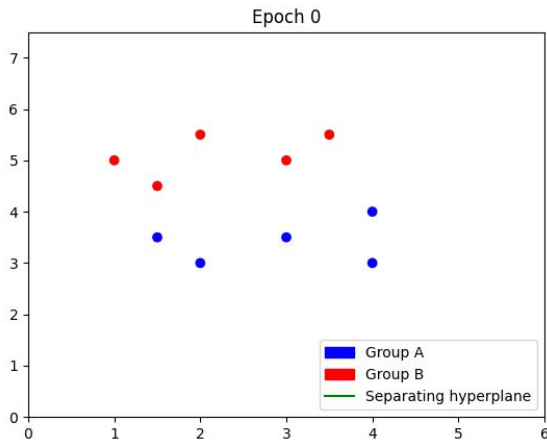
Input

$$X = (x_1, x_2) = (x, y)$$

Predicción

$$\hat{Y} = 1 = \text{blue box}$$



$$\hat{Y} = -1 = \text{red box}$$



Los grupos deben ser linealmente separables.



# Perceptrón lineal

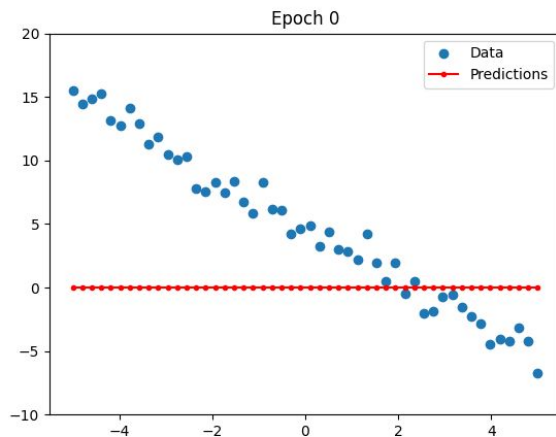








# Perceptrón lineal: usos

- Regresión (lineal).



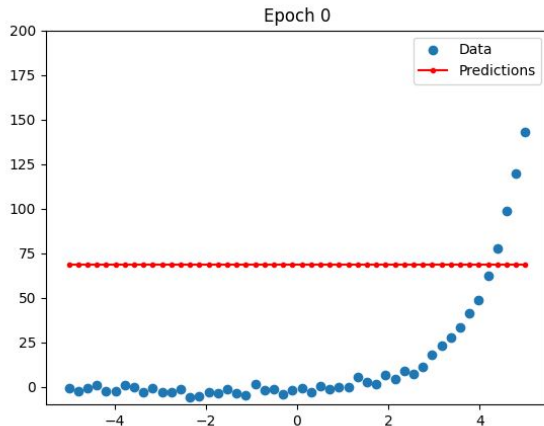
# Perceptrón no lineal





# Perceptrón no lineal: usos

- Clasificación binaria.
- Regresión (lineal y no lineal).





# **Aprendizaje y entrenamiento**





# Problema

Estimación del precio de una casa.

Al inicio, las predicciones  
serán aleatorias.



Tamaño de la Casa (m <sup>2</sup> )	Precio de la casa (miles de usd)	Predicción del precio
95	100	70
134	150	200
281	375	300

$x_1$

$y$

$\hat{y}$



# Función de costo


Se utiliza para medir qué tan mal está la predicción actual de la neurona, en comparación con la salida esperada.

Error cuadrático  
medio (MSE)

$$J = \frac{1}{n} \sum_{i=1}^n \overset{L}{(y^i - \hat{y}^i)^2}$$



# Aprendizaje



Cómo ajustamos las predicciones de la neurona para alcanzar las salidas esperadas?

$$w_i = (w_0, w_1, \dots, w_m)$$

$$\Delta w = (\Delta w_0, \Delta w_1, \dots, \Delta w_m)$$

$$w_{i+1} = w_i + \Delta w \longrightarrow \text{"aprendizaje"}$$



# Actualización de pesos

$$w_i = (w_0, w_1, \dots, w_m)$$

$$\Delta w = (\Delta w_0, \Delta w_1, \dots, \Delta w_m)$$

$$w_{i+1} = w_i + \Delta w$$

Para el **perceptrón escalón**, la actualización de pesos estará dada por:

$$\Delta w = \eta(y - \hat{y})x$$

$$\eta \in (0, 1)$$

Tasa de  
aprendizaje



$$w_i = (w_0, w_1, \dots, w_m)$$

$$\Delta w = (\Delta w_0, \Delta w_1, \dots, \Delta w_m)$$

$$w_{i+1} = w_i + \Delta w$$

# Actualización de pesos

Ejemplo:  $\Delta w = \eta(y - \hat{y})x$

$$\eta = 0.1$$

$$y = 1$$

$$\hat{y} = -1$$

$$x = (3, 4)$$

$$w_i = (1, 2)$$

$$\Delta w = 0.1(1 - (-1))(3, 4)$$

$$\Delta w = 0.2(3, 4)$$

$$\Delta w = (0.6, 0.8)$$


$$w_{i+1} = (1.6, 2.8)$$

$$\Delta w = \eta(y - \hat{y})x$$

# Actualización de pesos: ejemplo 1

$x$	$y$
(2, 5)	-1

$$w = [0.5, 1, -0.1] \quad \eta = 0.1$$



$$\Delta w = 0.1(-1 - 1)[1, 2, 5]$$

$$\Delta w = -0.2[1, 2, 5] = [-0.2, -0.4, -1]$$

$$w' = [0.5, 1, -0.1] + [-0.2, -0.4, -1]$$

$$w' = [0.3, 0.6, -1.1]$$

$$h' = 1 * 0.3 + 2 * 0.6 - 5 * 1.1$$

$$h' = -4$$

$$\theta(-4) = -1$$

$$\hat{y} = -1 = y$$



# Actualización de pesos

$$w_i = (w_0, w_1, \dots, w_m)$$

$$\Delta w = (\Delta w_0, \Delta w_1, \dots, \Delta w_m)$$

$$w_{i+1} = w_i + \Delta w$$

Para el **perceptrón lineal y no lineal**, la actualización de pesos estará dada por:

$$J = \frac{1}{n} \sum_{i=1}^n \boxed{(y^i - \hat{y}^i)^2}^L$$

Error cuadrático  
medio (MSE)

$$\Delta w = -\eta \frac{\partial L}{\partial w}$$

Gradiente  
descendente

$$\theta(h) = \hat{y}$$
$$\frac{\partial L}{\partial w} \overset{\uparrow}{=} \frac{\partial L}{\partial \theta} \frac{\partial \theta}{\partial h} \frac{\partial h}{\partial w}$$

Regla de  
la cadena



# Gradiente: ejemplo

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \theta} \frac{\partial \theta}{\partial h} \frac{\partial h}{\partial w}$$

Regla de la cadena

$$L = (y - \hat{y})^2 \longrightarrow \frac{\partial L}{\partial \theta} = \frac{\partial L}{\partial \hat{y}} = 2(y - \hat{y})(-1) = 2(\hat{y} - y)$$

Error cuadrático

$$\theta(h) = h \longrightarrow \frac{\partial \theta}{\partial h} = 1$$

Función identidad

$$h = \sum_{i=0}^m w_i x_i \longrightarrow \frac{\partial h}{\partial w} = (x_0, x_1, \dots, x_m)$$

Gradiente

$$\frac{\partial L}{\partial w} = 2(\hat{y} - y)(x_0, \dots, x_m)$$

$$\Delta w = -\eta \frac{\partial L}{\partial w}$$


$$w_{i+1} = w_i + \Delta w$$

$$\Delta w = -\eta \frac{\partial L(w)}{\partial w}$$

## Actualización de pesos: ejemplo 2

$x$	$y$
(2, 5)	-1

$$w = [0.5, 1, -0.1] \quad \eta = 0.02 \quad J = \text{MSE}$$



$$\frac{\partial L}{\partial w} = 2(\hat{y} - y)(x_0, \dots, x_m)$$

$$\Delta w = -0.02 \cdot 2(2 - (-1)) \cdot (1, 2, 5)$$

$$\Delta w = -0.12(1, 2, 5) = -(0.12, 0.24, 0.6)$$

$$w' = [0.5, 1, -0.1] - [0.12, 0.24, 0.6]$$

$$w' = [0.38, 0.76, -0.7]$$

$$h' = 1 * 0.38 + 2 * 0.76 - 5 * 0.7$$

$$h' = -1.6$$


$$\theta(-1.6) = -1.6$$

$$\hat{y} = -1.6$$


# Bonus: Optimización



# Optimización de pérdida



# GD con Momentum



$$\Delta w_{i+1} = -\eta \frac{\partial L}{\partial w} + \alpha \Delta w_i$$

$$\alpha \in (0, 1)$$



# Fin

